

### GİRİŞ

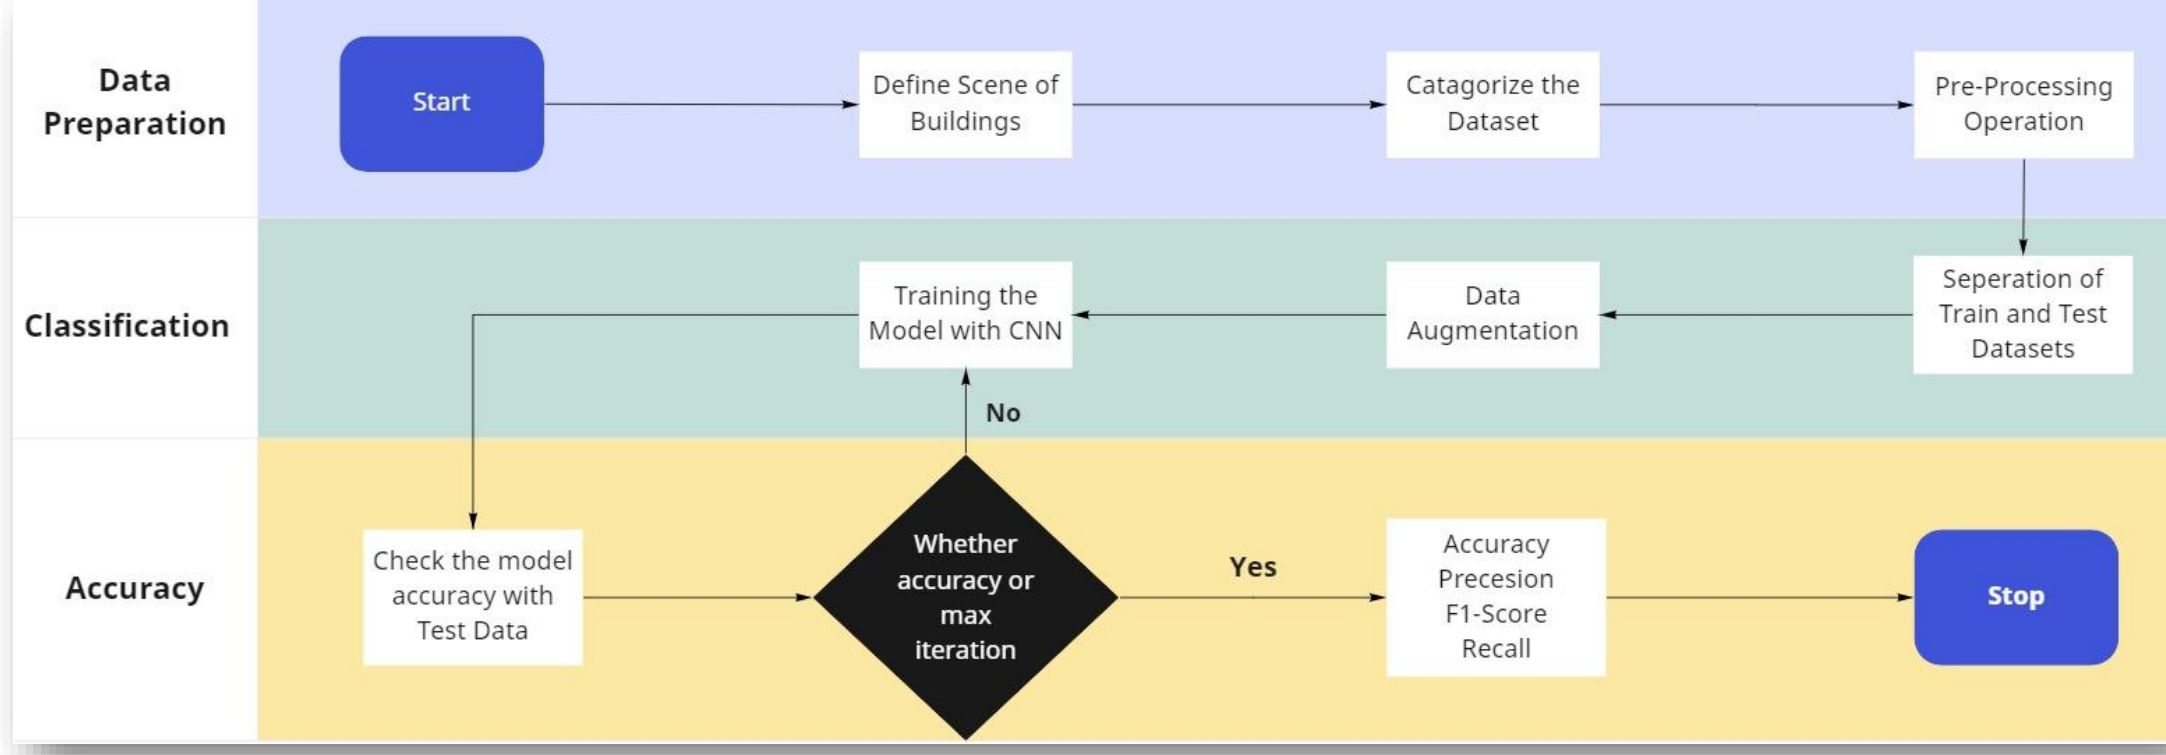
Doğal afetler sonucunda binalarda meydana gelen hasarlar insan hayatını olumsuz etkilemektedir. Bu nedenle son zamanlarda hasarlı alan hakkında bilgi toplayarak hasar tespiti için uzaktan algılama teknikleri kullanılmaktadır. Bu çalışma, 6 Eylül 2017 tarihinde Sint Maarten adasında meydana gelen Irma Kasırgası'nın sebep olduğu bina hasarını ve bu binaların hasar derecelerini uzaktan algılama yöntemleriyle tespit etmeyi amaçlamaktadır(Kersbergen, 2017). Çalışmada, kasırgadan etkilenen bölgenin olay sonrası İHA görüntüleri kullanılarak hasar tespitinde derin öğrenme yöntemlerinden biri olan Konvolüsyonel Sinir Ağları (CNN) uygulanmaktadır(Vetrivel, 2016). GlobalMedic'in RescUAV Programı tarafından üretilen İHA görüntüleri kullanılmaktadır. Bu çalışmada, 4 cm çözünürlüklü RescUAV görüntüleri elde edildi ve 8 cm çözünürlüklü görüntüler elde etmek için yeniden örneklendirildi. Bina hasar tespit sürecinin doğruluk kontrolünde, çalışma alanına ait Copernicus platformundan sağlanan vektör referans verileri ve olay sonrası WorldView-2 uydu görüntüleri kullanılmaktadır.



Şekil 1. Sint Maarten ülkesinin konumu

### YÖNTEM

Uygulanan yöntemin adımları Şekil 2'de görüldüğü gibidir.



Şekil 2. Metodolojik çerçevenin şematik diyagramı

**A – Veri Hazırlama:** Binaların hasar derecelerine göre sınıflandırılan veriler CNN modelinde kullanılmak üzere QGIS platformunda hazırlanmaktadır. Veriler hazırlanırken Copernicus sayfasının Irma kasırgası için hazırladığı Sint Maarten Adası'nın olay öncesi görüntüsü ve bina hasar etiketleri referans alınmaktadır. Verileri hazırlama adımları aşağıdaki gibidir:


**I.** Her hasar sınıfı için ayrı vektör dosyaları oluşturulmuş, nokta geometri tipi seçilmiştir. Hasar sınıfları şu şekildedir: hafif hasarlı, orta hasarlı ve yüksek/tamamen hasarlı (Şekil 3). Copernicus verileri referans alınarak bina çatılarının orta noktalarına noktalar atanmaktadır.

**II.** Daha sonra QGIS buffer aracı kullanılarak bu noktalara kare tamponlar eklenmiştir. Binalar için uygun bulunan tamponun kenar uzunluğu 9 m olarak belirlendi. Elde edilen tamponlar poligon geometri tipi olarak kaydedilmiştir (Şekil 4).


**III.** QGIS'te maske katmanına göre klip tarama aracı kullanılarak, raster görüntüdeki binalar iteratif bir şekilde kırpıldı ve kaydedildi.

**IV.** Hazırlanan verilerin sınıf doğruluğu ve modelde kullanılabilirliği kontrol edildi.

Ek olarak, her sınıftan 1000'er adet olmak üzere toplam veri sayısı 3000 adettir. Bu verilerin 2700 adeti eğitim için, 300 adeti test için kullanılmaktadır.



Şekil 3. Hasar sınıfları. (a) hafif hasarlı; (b) orta hasarlı; (c) yüksek/tamamen hasarlı.




Şekil 4. Noktaların ve tampon alanların binalar üzerindeki görünümü

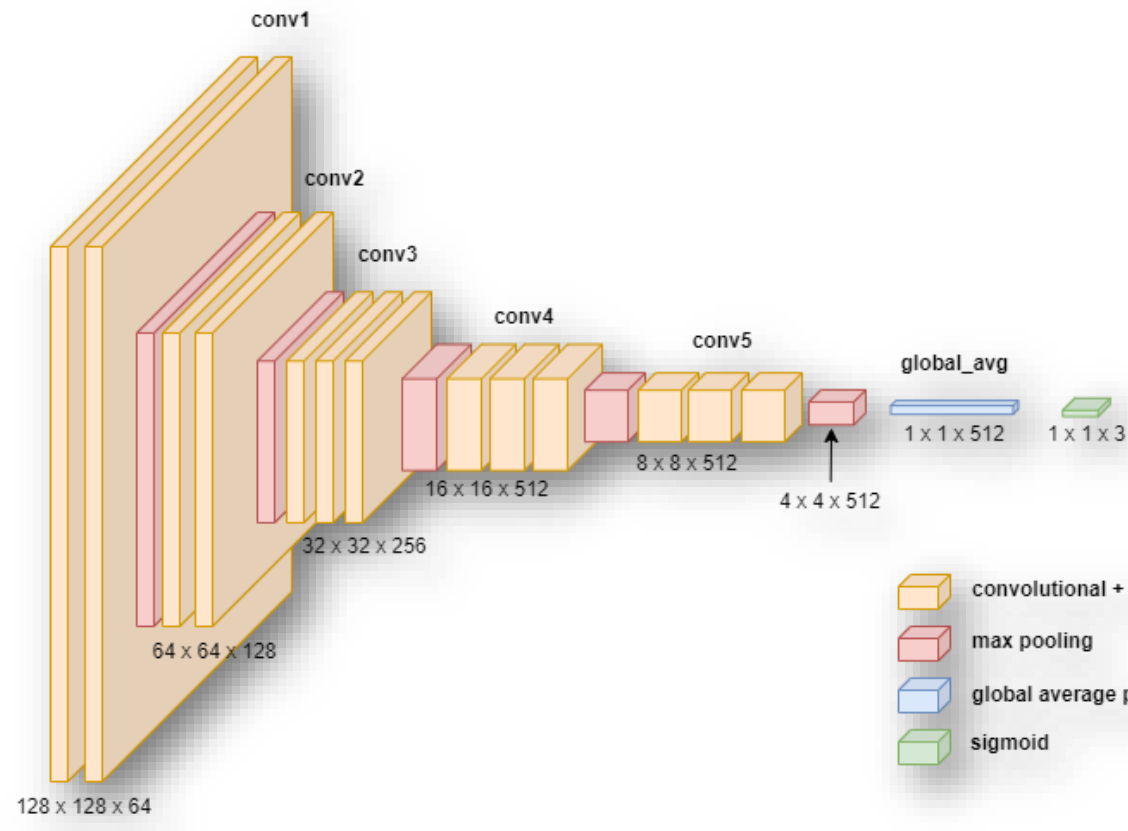
### B – CNN Modelinin Hazırlanması

Çalışmada makine öğrenmesi uygulamalarında kullanılan TensorFlow çerçevesi python programlama dilinde kullanılmaktadır. TensorFlow içerisinde çalışan Keras kütüphanesi de bu çalışmada yer almaktadır. Çalışma ortamı Google Collab olarak belirlenmiştir. Bu sayede kütüphanelerin ve çerçevelerin bilgisayar belleğinde yer kaplamaması sağlanır. Hazırlanan veriler Google Drive'da saklanmaktadır. Bu projede bina hasar tespiti için 2 model kullanılmaktadır. İlk model proje üyeleri tarafından hazırlanmaktadır. İkinci model ise dünya genelinde sınıflandırma ve tespit çalışmalarında sıklıkla kullanılan VGG-16 mimarisidir. İki modelde de görüntü giriş boyutu 128x128 pikseldir. Bu iki modelin eğitim, doğrulama ve test doğrulukları karşılaştırılmış ve değerlendirilmiştir.

Proje sahipleri tarafından CNN mimarisinde 3 adet konvansiyonel ağ katmanı, 3 adet maksimum havuzlama katmanı ve 1 adet tam bağlantılı katman bulunmaktadır. Bu mimaride yığın normalleştirme tekniği de kullanılmaktadır. Modelin mimarisi Şekil 5'te gösterilmektedir. VGG-16, 13 adet konvansiyonel ağ katmanı, 5 adet havuz katmanı ve 1 adet küresel ortalama havuz katmanından oluşan bir CNN mimarisidir (Şekil 6).




Şekil 5. Proje üyeleri tarafından oluşturulan CNN mimarisi




Şekil 6. VGG-16 mimarisi

### SONUÇLAR

CNN mimarisi kullanılarak yapılan bina hasar tespit çalışmasında iki CNN modeli tarafından doğruluk sonuçları elde edilmektedir.




Şekil 7. Proje üyeleri tarafından oluşturulan CNN modelinin doğruluk ve hata grafikleri




Şekil 8. VGG 16 CNN modelinin doğruluk ve hata grafikleri

Proje üyeleri tarafından hazırlanan modelin sonuçlarına göre %84,53 eğitim doğruluğu ve %83 test doğruluğu elde edilmektedir. Öğrenme aktarımı yapılan VGG-16 modelinin eğitim ve test doğruluğu için ince ayar(fine-tuning) öncesi ve sonrası olmak üzere iki sonuç elde edildi. İnce ayar öncesi eğitim doğruluğu %74,58, test doğruluğu %78'dir. İnce ayar sonrası, hem eğitim hem de test doğruluğu artmaktadır, eğitim doğruluğu %83,15 ve test doğruluğu %84'tür.



Şekil 9. Proje üyeleri tarafından oluşturulan CNN modelinin hata matrisi



Şekil 10. VGG 16 CNN modelinin hata matrisi

✓ Her iki modelin ağırlıkları, bina hasar tespiti için gelecek çalışmalarda kullanılmak üzere kaydedilmektedir.

✓ İki modelde de yüksek/tamamen hasarlı ve hafif hasarlı binaların tespitinde yüksek doğrulukta sonuç elde edilmektedir.

✓ VGG 16 modelinde en iyi uyum sağlanmaktadır.

✓ Veriler hazırlanırken binaların ve bina çevrelerinin fiziksel özelliklerinden dolayı veri sayısını ve doğruluğu düşüren bazı sorunlarla karşılaşıldı. Kasırga sonrası mavi muşamba kaplı binalardan, hasar derecesi farklı bitişik binalardan, tampon boyutunu aşan geniş yüzeyli binalardan ve beton çatılı binalardan hasar derecesi tespiti için veri toplanmadı. Güneş paneline sahip binaların az sayıda olması modelin eğitimi için yeterli bulunmadığından, bu binalardan da veri toplanmadı.

### ÖNERİLER

- Afet sonrası olay mahallinden otomatik olarak veri toplayabilen ve ilgili bölge için kırpmayı otomatik olarak gerçekleştirebilen bir eklenti tasarlamak ilerdeki çalışmalar için birçok kolaylık sağlayacaktır.
- Bina hasar sınıflarının veri sayısı artırılarak çalışmanın doğruluğu yükseltilecektir.
- Bu çalışmada üretilen modelin ağırlıkları kullanılarak, meydana gelen başka afetler sonucunda acil yardımın hızlı bir şekilde başlatılması ve tespit edilmesi için ilgili bölgedeki hasarlı binaların hasar dereceleri belirlenebilecektir.

### KAYNAKLAR

D. Kersbergen, "Automated Building Damage Classification using Remotely Sensed Data Case study: Hurricane Damage on St. Maarten", 2017.

A. Vetrivel, M. Gerke, N. Kerle, F. Nex and G. Vosselman, "Disaster damage detection through synergistic use of deep learning and 3D point cloud features derived from very high resolution oblique aerial images, and multiple-kernel-learning", ISPRS Journal of Photogrammetry and Remote Sensing, March, 2016.

